第4回　データに関する理解(3)

2026/10/14

今回やること

1. 散布度と前回の復習
2. 四分位数
3. 分散・標準偏差
4. 相関関係
5. 外れ値

1. 散布度と前回の復習
2. 四分位数
3. 分散・標準偏差
4. 相関関係
5. 外れ値

1. 散布度と前回の復習

基本統計量と基礎集計（再掲）

- 大量のデータについて、そのデータの基本的な性質を表す指標を、**基本統計量**という。
  - ✓**代表値**：そのデータ全体の特徴や傾向を表す。　先週
    - ➢ 例：平均値、中央値
  - ✓**散布度**：そのデータの散らばりを表す。　今週
    - ➢ 例：分散、四分位範囲
- 大規模なデータ分析を行う前には、**基礎集計**を行う。
  - ✓データのクリーニング：外れ値の除去する。　今週
  - ✓基本統計量の計算
  - ✓データの可視化：グラフや図で表す。　第10回
  - ✓単純な集計：男女などの構成比を計算する。

散布度の必要性

- 平均値が同じでも、まったく性質の異なるデータである可能性が考えられる。
  - ✓性質の違いを見るために、散布度が必要。
- 例：10人のテスト　どちらも平均点は40点
  - ✓集団A　平均点だと上位
    - ➢ 50点，40点，40点，40点，39点，39点，39点，38点，38点，37点
  - ✓集団B　平均点だと真ん中
    - ➢ 60点，60点，60点，55点，50点，40点，30点，20点，15点，10点
  - 違いは散らばり具合(散布度)
  - ✓どちらの集団で平均点を取る方がうれしい？

花子さん・太郎さん一家の体重（再掲）

No	名前	体重(kg)
1	花子さん	30
2	太郎さん	40
3	お兄さん	90
4	お姉さん	45
5	お父さん	80
6	お母さん	65
7	お祖父さん	50
8	お祖母さん	45

- 今回は、花子さん、太郎さん、お兄さん、お姉さん、お母さん、お父さん、お祖父さん、お祖母さんからなる8人家族の代表値を計算します。
- 皆さんに配布した、xxxx_4.xlsxに同じデータがあります。

平均値(1)（復習）

- すべてのデータを足し合わせた合計を、データの個数で割った値を**平均値**(相加平均)という。
  - ✓そのほかにも、相加平均、調和平均などもある。

$$\bar{x} = \frac{1}{n}\sum_{k=1}^{n} x_k$$

その集団の傾向を説明する値。

- 8人家族の例

$$\text{平均値} = \frac{30+40+90+45+80+65+50+45}{8} = 55.625\ \text{kg}$$

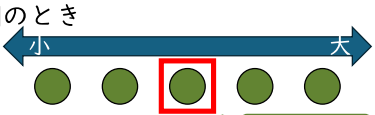
単位をつけて答える。

平均値(2)（復習）

- 平均値には、データの中に極端に小さい値や大きい値があると、極端な値の影響で、実際の傾向からずれるという問題点がある。
- 具体的な例(理由を考えてみよう。)：
  - ✓日本全体の平均年収は約477万円である。
  - ✓しかし、花巻東高校のOB・OGの平均年収は約4000万円である。
- 具体的な例の理由
  - ✓花巻東高校の卒業生に、大谷翔平がいる。
  - ✓彼の年収が推定150億円であるため、その値に影響されている。

中央値（メジアン）(1)（復習）

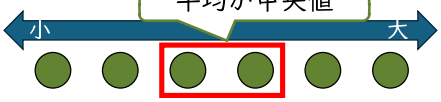
- データを小さい順から大きい順に並べたときに、ちょうど真ん中にくる値を、**中央値**(メジアン)という。
- 値が奇数個のとき



中央値

- 値が偶数個のとき

平均が中央値



中央値（メジアン）(2)（復習）

- 中央値は、データの中の極端な値に影響を受けにくい。
- 8人家族の例
  - ✓小さい順に並べる。

30，40，45，**45，50，** 65，80，90

  - ✓真ん中に来るのは45と50

$$\text{中央値} = \frac{45+50}{2} = 47.5\ \text{kg}$$

単位をつけて答える。

1. 散布度と前回の復習
2. **四分位数**
3. 分散・標準偏差
4. 相関関係
5. 外れ値

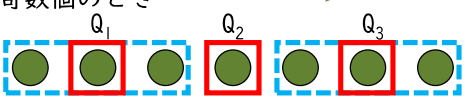
2. 四分位数

四分位数（1）

- データを小さい順に並べたとき、全体の個数を4等分する3つの区切りの値を、**四分位数**という。
  - ✓第1四分位数(Q_1)：全体の低い方から25%の位置の値。
  - ✓第2四分位数(Q_2)：データの真ん中の値、中央値。
  - ✓第3四分位数(Q_3)：全体の高い方から25%の位置の値。
- データのばらつきや、分布を大まかに把握するために求める。
  - ✓例：テストで○○点以上なら、上位25%だな。
- 中央値と同様に、極端な値の影響を受けにくい。

四分位数 (2)

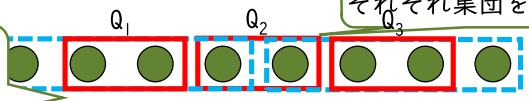
- 求め方としては、以下の通り。
  - ✓値が奇数個のとき



Q_2を除いて2つの集団をつくる。

各集団の中央値が四分位数。

  - ✓値が偶数個のとき



Q_2となる2つの値で、それぞれ集団をつくる。

各集団の中央値が四分位数。

四分位数 (3)

- 8人家族の例
  - ✓小さい順に並べる。

30，40，45，45，50，65，80，90

中央値(Q_2)は47.5kg

  - ✓それぞれの集団をつくる。

30，40，45，45，50，65，80，90

  - ✓各集団の中央値を求めると、以下の通り。
    - ➢ Q_1：42.5kg
    - ➢ Q_2：47.5kg
    - ➢ Q_3：72.5kg

単位をつけて答える。

四分位範囲

- 第3四分位数から第1四分位数を引いた値を、**四分位範囲**という。

$$Q_3 - Q_1$$

- そのデータについて、中央の50%が収まる幅を求めた値となる。
  - ✓値が大きければ、ばらつきが大きい。
  - ✓値が小さければ、ばらつきが小さい
- 8人家族の例
  - ✓Q_1が42.5kg、Q_3が72.5kgなので、

$$\text{四分位範囲} = 72.5 - 42.5 = 30\text{kg}$$

単位をつけて答える。

四分位偏差

- 四分位範囲を2で割ったものを、**四分位偏差**という。

$$\frac{Q_3 - Q_1}{2}$$

- 第1四分位数と、第3四分位数が、どれくらい中央値から離れているか見るために計算する。
  - ✓値が大きければ、ばらつきが大きい。
  - ✓値が小さければ、ばらつきが小さい。
- 8人家族の例
  - ✓四分位範囲が30kgなので、

$$\text{四分位偏差} = 30 \div 2 = 15\text{kg}$$

単位をつけて答える。

Excelにおける四分位数の関数

- 第n四分位数を求める関数

= QUARTILE.INC(範囲始め:範囲終わり，n)

  - ✓例：「= QUARTILE.INC(A1:A10,1)」なら、A1からA10についての第1四分位数。
  - ✓ただし、先ほどまで説明した方法とは違う計算方法のため、手計算と値が一致しない可能性がある。
    - ➢ Excelを使う上では、そこまで気にしなくてもよい。
- 四分位範囲や四分位偏差を求める関数はない。
  - ✓上記の関数を使って、第1四分位数と第3四分位数を求めて、計算する。

演習1：四分位数の計算

演習

1. UNIPAの「xxxx_4.xlsx」をダウンロードする。
2. xxxx部分を、自分の学籍番号に変更する。
3. ファイル内の、「演習問題」シートに移動する。
4. 演習1に従い、問題を解け。

1. 散布度と前回の復習
2. 四分位数
3. **分散・標準偏差**
4. 相関関係
5. 外れ値

3. 分散・標準偏差

分散（1）

- データがどの程度平均の周りにばらついているかを表す値を、**分散**という。
  - ✓データ全体の平均値と、各データの値との差を、**偏差**という。（平均からどれくらい離れているか。）
  - ✓すべての偏差を二乗し、その平均値が分散になる。
    - ➢ 二乗するのは、偏差をすべて正の数にするため。

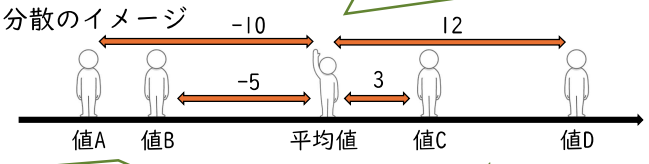
$$\sigma^2 = \frac{1}{n}\sum_{k=1}^{n}(x_k - \bar{x})^2$$

  - ✓分散の値が大きければ、ばらつきも大きい。
  - ✓分散の値が小さければ、ばらつきも小さい。
- 平均値を用いるため、極端な値の影響を受けやすい。

分散（2）

平均値から大体どれくらい離れているか知りたい。

- 分散のイメージ



差(偏差)が負となる場合もあるので、差(偏差)を二乗して正の数にする。

その平均値を、分散とする。

分散（3）

- 8人家族の例
  - ✓体重の平均値は、55.625kg
  - ✓偏差は花子さんからお祖母さんまで、以下の通り。
    -25.625，-15.625，34.375，-10.625，24.375，9.375，-5.625，-1.0625
  - ✓偏差を二乗すると、以下の通り。
    656.640625，244.140625，1181.640625，112.890625，594.140625，87.890625，31.640625，112.890625
  - ✓上記の平均値を計算すると、分散が求まる。
    分散 = 377.734375

Excelにおける分散の関数

- 分散を求める関数
  = VAR.P(範囲始め:範囲終わり)
  - ✓例：「= VAR.P(A1:A10)」なら、A1からA10の分散。
  - ✓他にも分散を求める関数があるが、今回の講義では上記の関数を使用すればよい。
    - ➢ 実際には、母集団や標本などによって使い分ける。

標準偏差（1）

- 分散は、偏差を二乗した値のため、そのままでは「このテストは平均から大体〇〇点離れている」といった指標には使用できない。
- 分散の値の正の平方根を、**標準偏差**という。
  - ✓二乗している値の平方根なので、どれくらい平均値から離れているのか、直感的に分かりやすい指標となる。
  - ✓例：標準偏差が8点だから、このテストでは大体平均値から8点離れている。

$$\sigma = \sqrt{\frac{1}{n}\sum_{k=1}^{n}(x_k - \bar{x})^2}$$

標準偏差 (2)

- 8人家族の例
  - ✓分散が377.734375であるため、この値の正の平方根が標準偏差となる。
    $$\text{標準偏差} = \sqrt{377.734375} \approx 19.44\text{kg}$$
  - ✓割り切れない場合は、適当なところで四捨五入する。

単位をつけて答える。

Excelにおける標準偏差の関数

- 標準偏差を求める関数

  = STDEV.P(範囲始め:範囲終わり)
  - ✓例
    - ➢ 「= STDEV.P(A1:A10)」なら、A1からA10の標準偏差。
  - ✓他にも分散を求める関数があるが、今回の講義では上記の関数を使用すればよい。
    - ➢ 実際には、母集団や標本などによって使い分ける。

演習2：分散・標準偏差の計算

演習

1. UNIPAの「xxxx_4.xlsx」をダウンロードする。
2. xxxx部分を、自分の学籍番号に変更する。
3. ファイル内の、「演習問題」シートに移動する。
4. 演習2に従い、問題を解け。

1. 散布度と前回の復習
2. 四分位数
3. 分散・標準偏差
4. **相関関係**
5. 外れ値

4. 相関関係

相関関係

- 2つの事柄について、一方の値が増加すると、もう一方の値が減少、または増加する関係を、**相関関係**という。
  - ✓例：雨量とその地域の川の水量
  - ✓特に、一方の値が増加したときに、もう一方の値が減少する関係を、**負の相関**という。
    - ➢ 例：地球全体の気温と、北極や南極の氷の量

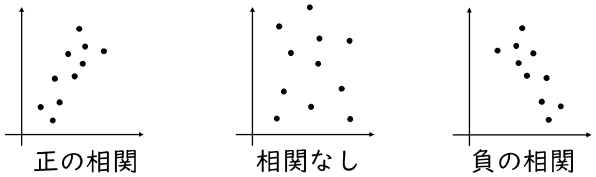


  - ✓逆に、一方の値が増加したときに、もう一方の値が増加する関係を、**正の相関**という。
    - ➢ 例：アイスクリームの売上と気温



相関関係と散布図

- 2つのデータを縦軸と横軸に対応させ、データを点として打ったグラフを、**散布図**という。
  - ✓散布図を作成すると、2つのデータについてどのような関係(正の相関、負の相関、相関なし)があるか直感的に理解できる。



相関係数（1）

- 2つのデータの間にある線形的な相関関係やその関係の強さを、数値として表す指標を、**相関係数**（ピアソン相関係数）という。

$$r = \frac{s_{xy}}{s_x s_y}$$

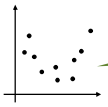
✓s_xはデータxの標準偏差、s_yはデータyの標準偏差、s_{xy}はx, yの**共分散**を表す。

- 相関係数は、$-1 \leq r \leq 1$となる。
  - ✓-1に近いほど、負の相関が強い。
  - ✓0に近いほど、相関なし。
  - ✓1に近いほど、正の相関が強い。

2つのデータの傾向が一定の規則になっているか見る値

相関係数（2）

- 相関係数の一般的な目安
  - ✓$\pm 0.7 \sim \pm 1.0$：強い相関がある。
  - ✓$\pm 0.4 \sim \pm 0.7$：相関がある。
  - ✓$\pm 0.2 \sim \pm 0.4$：弱い相関がある。
  - ✓$\pm 0.0 \sim \pm 0.2$：ほとんど相関がない。
- 相関係数は、直線関係しか見えないので、実際には散布図と合わせて確認する。



直線関係はないが、放物線（2次関数）関係はある。

相関係数（3）

- 相関係数の例
  - ✓学生5人の予習時間と小テストの得点

No.	予習時間(x)	小テストの得点(y)	xの偏差	yの偏差	(x偏差)×(y偏差)
1	1	3	−2	−1	2
2	2	2	−1	−2	2
3	3	4	0	0	0
4	4	6	1	2	2
5	5	5	2	1	2
平均	3	4			1.6
分散			2	2	
標準偏差			1.41	1.41	
相関係数					0.8

相関係数（3）

- 相関係数の例
  - ✓学生5人の予習時間と小テストの得点

No.	予習時間(x)	小テストの得点(y)	xの偏差	yの偏差	(x偏差)×(y偏差)
1	1	3	−2	−1	2
2	2	2	−1	−2	2
3	3	4	0	0	0
4	4	6	1	2	2
5	5	5	2	1	2
平均	3	4			1.6
分散			2	2	
標準偏差			1.41	1.41	
相関係数					0.8

相関係数
$$\frac{xyの共分散}{xの標準偏差 \times yの標準偏差}$$

相関係数（3）

- 相関係数の例
  - ✓学生5人の予習時間と小テストの得点

No.	予習時間(x)	小テストの得点(y)	xの偏差	yの偏差	(x偏差)×(y偏差)
1	1	3	−2	−1	2
2	2	2	−1	−2	2
3	3	4	0	0	0
4	4	6	1	2	2
5	5	5	2	1	2
平均	3				1.6
分散				2	
標準偏差				1.41	1.41	
相関係数					0.8

強い正の相関がある。

Excelにおける相関係数の関数

- 相関係数を求める関数
  - = CORREL(1つ目のデータ範囲，2つ目のデータ範囲)
  - ✓例
    - ➢「= CORREL(A1:A10, B1:B10)」なら、A1からA10のデータと、B1からB10のデータの相関係数。

相関関係と因果関係（1）

- 相関関係は、2つのデータが連動する関係である。
- 因果関係は、一方が原因となり、もう一方が結果となる関係である。
- 相関関係と因果関係は、混同しやすいが、相関関係があるからといって、因果関係がある訳ではない。
  - ✓例1：犯罪件数とその地域の交番の数
    - ➢ 正の相関があるが、交番の数が多い(原因)から、犯罪件数が多い(結果)わけではない。(原因と結果の逆転)
  - ✓例2:ある俳優の映画出演本数とプールでの溺死者数
    - ➢ 単なる偶然

相関関係と因果関係（2）

- ✓例3：海難事故の件数と、アイスクリームの売上
  - ➢ アイスクリームが売れるほど、海難事故が増えるわけではない。
  - ➢ 夏はアイスクリームが売れるし、海にも行くので海難事故が増える。
  - ➢ 「夏」という隠れた要因がある。(**疑似相関**)

演習3：相関係数の計算

演習

1. UNIPAの「xxxx_4.xlsx」をダウンロードする。
2. xxxx部分を、自分の学籍番号に変更する。
3. ファイル内の、「演習問題」シートに移動する。
4. 演習3に従い、問題を解け。

1. 散布度と前回の復習
2. 四分位数
3. 分散・標準偏差
4. 相関
5. 外れ値

5. 外れ値

外れ値

- 得られたデータの中で、大多数のデータから大きくかけ離れた極端な値を、**外れ値**という。
  - ✓外れ値の内、測定ミスや記入ミスなど、原因が分かっているものを、異常値とよぶこともある。
- 例：一般的な会社員の年収データに、大谷翔平の年収データが混ざった場合、大谷翔平の年収データは外れ値。

外れ値の判定方法（1）

- 代表的な外れ値の判定方法（これ以外にもある。）
- 四分位範囲法(IQR法)
- 第1四分位数(Q_1)と第3四分位数(Q_3)、四分位範囲(IQR)を用いる方法。
  - ✓$Q_1-1.5\times IQR$より小さい値と、$Q_3+1.5\times IQR$より大きい値を外れ値と考える。

外れ値の判定方法 (2)

- ある授業で、7人の学生が小テストを受験した。それぞれの学生が回答完了までかかった時間(分)は以下の通り。

  25, 30, 35, 40, 45, 50, 95

- このとき、 Q_1=30、 Q_3=50、IQR=Q_3-Q_1=20となる。
- 外れ値の境界は、以下の通り。
  - ✓Q_1-1.5×IQR=0(正常値の下限)
  - ✓Q_3+1.5×IQR=80(正常値の上限)
  - ✓0分未満、または80分超のデータが外れ値。
- よって、95分のデータは外れ値となる。

演習4：外れ値の計算

演習

1. UNIPAの「xxxx_4.xlsx」をダウンロードする。
2. xxxx部分を、自分の学籍番号に変更する。
3. ファイル内の、「演習問題」シートに移動する。
4. 演習4に従い、問題を解け。

練習：散布度の総括

演習

1. UNIPAの「xxxx_4.xlsx」をダウンロードする。
2. xxxx部分を、自分の学籍番号に変更する。
3. ファイル内の、「練習問題」シートに移動する。
4. 練習1、練習2の問題文に従い、問題を解け。

おわりに

- UNIPAの情報リテラシーⅡの第4回の課題として以下のファイルを提出してください。
  - ✓「xxxx(学籍番号)_4.xlsx」
- 期限は2026/10/20(火)**16:00**まで。
- 次回の講義は、**10/28(火)**です。
  - ✓来週は月曜日課のため、お休み。
- PCをシャットダウンしましょう。